

Informe del módulo de interfaz visual

CSDI RAG Engine

1 Módulo de interfaz visual

El módulo de interfaz visual es la capa de presentación del sistema CSDI RAG Engine. Su responsabilidad es exponer todas las capacidades del backend a través de una aplicación web interactiva que un operador o usuario final puede utilizar desde un navegador, sin necesidad de interactuar directamente con la API REST ni con herramientas de línea de comandos.

La interfaz no implementa lógica de negocio: actúa como cliente de la API del servidor, que opera en el puerto configurado por la variable `APP_PORT` (por defecto `8888`). Todos los datos que muestra provienen de respuestas de esa API; no existe estado local persistente en el cliente más allá del identificador de sesión de conversación. Esta separación es deliberada: mantener la interfaz como cliente puro de la API garantiza que cualquier modificación al pipeline, al índice o a los modelos sea inmediatamente reflejada en lo que muestra la interfaz, sin necesidad de coordinar cambios entre capas.

La interfaz está compuesta por ocho secciones principales, cada una dedicada a un dominio funcional distinto del sistema: consulta en lenguaje natural, historial de conversación, búsqueda directa sobre el índice, configuración del pipeline, gestión de fuentes e ingesta, monitorización operativa, retroalimentación de consultas y evaluación de calidad.

2 Panel de chat RAG

Función del panel. Es la sección de uso cotidiano del sistema. Permite formular preguntas en texto libre y recibir respuestas generadas por el modelo de lenguaje, fundamentadas en fragmentos recuperados del corpus de documentación interno o de la web. Es el punto de entrada principal para cualquier usuario que desee consultar información del corpus sin conocer la estructura del índice.

Datos presentados. La respuesta del endpoint `POST /api/v1/rag/query` incluye todos los campos necesarios para que la interfaz muestre tanto la respuesta como su procedencia completa. El campo **answer** contiene el texto generado por el modelo en español. El campo **sources** es una lista de fragmentos utilizados para construir la respuesta: cada fuente incluye el título del documento, la URL de origen, el tipo de fuente (**corpus** o **web_cache**), el método de recuperación (**bm25**, **vector**, **hybrid** o **web_cache**), la puntuación de relevancia, la puntuación de frescura, la prioridad de visualización y el rango de posicionamiento. El campo **model** identifica el modelo exacto que generó la respuesta. Los campos **prompt_tokens** y **completion_tokens** reportan el consumo de tokens de la llamada. Cuando se ejecutó búsqueda web, los campos **cache_searched**, **cache_hits**, **external_search_executed** y **external_indexed_count** informan sobre el alcance de esa búsqueda.

La respuesta presenta una separación visual entre la información proveniente del corpus interno y la obtenida de búsqueda web. Cuando todos los fragmentos son del corpus, la respuesta no incluye ninguna indicación de búsqueda web. Cuando los fragmentos son exclusivamente de la web, la respuesta indica explícitamente que no se encontró información en el corpus interno. Cuando hay

fragmentos de ambas fuentes, la respuesta distingue qué parte de la información proviene de cada origen.

Parámetros editables.

Parámetro	Descripción
<code>query</code>	Pregunta en texto libre. Longitud mínima: 1 carácter.
<code>session_id</code>	Identificador de sesión opcional (8–128 caracteres alfanuméricos y guiones). Cuando se incluye, el intercambio queda registrado en el historial de conversación.

3 Panel de historial de conversación

Función del panel. Muestra la secuencia completa de preguntas y respuestas de una sesión identificada por su `session_id`. Permite al usuario revisar interacciones anteriores sin necesidad de repetir consultas. El historial es consultable en cualquier momento durante el tiempo de vida de la sesión, que por defecto es de 7 días (`CHAT_HISTORY_TTL_SECONDS=604800`), renovado en cada intercambio.

Datos presentados. El endpoint `GET /api/v1/rag/history/{session_id}` devuelve una lista ordenada de mensajes. Cada entrada incluye un identificador único, el tipo de mensaje ("`user`" para preguntas, "`assistant`" para respuestas), el contenido textual, la marca temporal en formato ISO 8601, la lista de fuentes citadas y el nombre del modelo utilizado en el caso de los mensajes del asistente.

Parámetros editables.

Parámetro	Descripción
<code>session_id</code>	Identificador de sesión a consultar. Debe coincidir con el usado durante las consultas en el panel de chat.

4 Panel de búsqueda híbrida

Función del panel. Permite ejecutar búsquedas directas sobre el índice sin pasar por el modelo generativo. Su utilidad principal es exploratoria y de diagnóstico: permite verificar qué fragmentos recupera el sistema ante una consulta concreta, comparar los resultados de la búsqueda léxica frente a la vectorial, y depurar el comportamiento del pipeline de recuperación. Expone tres modalidades: búsqueda híbrida sobre el corpus, búsqueda híbrida sobre el caché web y búsqueda con expansión por retroalimentación de consultas.

Datos presentados. El endpoint `POST /api/v1/search` devuelve por cada resultado el identificador del fragmento (`chunk_id`), la puntuación de relevancia RRF (`score`), la URL del documento de origen, el título, el *breadcrumb* de navegación, el texto completo del fragmento y el conjunto `found_by`, que indica si el fragmento fue encontrado por BM25, por el recuperador vectorial o por ambos. La búsqueda sobre el caché web (`POST /api/v1/search/web-cache`) devuelve la misma estructura pero limitada a los fragmentos indexados de búsquedas web anteriores.

Parámetros editables.

Parámetro	Descripción
query	Texto de la consulta a ejecutar.
top_k	Número máximo de resultados a devolver.
source_ids	Lista opcional de identificadores de fuente para filtrar los resultados a una o varias fuentes específicas.

5 Panel de configuración del pipeline

Función del panel. Es la sección de mayor impacto operativo del sistema. Permite ajustar en tiempo de ejecución todos los parámetros que controlan el comportamiento del pipeline RAG sin necesidad de reiniciar el servidor ni modificar las variables de entorno. Los cambios se persisten en el archivo `pipeline_config.json` y sobreviven a reinicios del servidor, de modo que la configuración ajustada se convierte en el nuevo estado base del sistema.

La existencia de este panel responde a la naturaleza exploratoria del ajuste de sistemas RAG. Los valores óptimos de temperatura, número de fragmentos de contexto, pesos de fusión o umbrales del detector de insuficiencia dependen del corpus específico y del perfil real de consultas, y no son conocidos a priori. Poder modificarlos y observar el efecto sobre las respuestas sin interrumpir el servicio reduce significativamente el ciclo de experimentación.

Datos presentados. El endpoint `GET /api/v1/config` devuelve la configuración activa completa. Al cargar el panel se muestran todos los parámetros vigentes agrupados por categoría: pesos de fusión híbrida, configuración del modelo LLM, estado y parámetros del reordenador, estado de HyDE, y los quince parámetros del detector de insuficiencia.

Fusión híbrida.

Parámetro	Default	Descripción
bm25_weight	0.3	Peso del recuperador léxico BM25 en la fusión RRF.
vector_weight	0.7	Peso del recuperador vectorial en la fusión RRF.

Los dos pesos deben sumar 1,0. Un peso BM25 más alto favorece coincidencias exactas de términos técnicos; un peso vectorial más alto favorece similitud semántica entre idiomas distintos. El sistema valida la restricción de suma antes de aplicar los cambios.

Modelo de lenguaje.

Parámetro	Default	Descripción
llm_base_url	<code>https://api.mistral.ai/v1</code>	URL del proveedor LLM.
llm_api_key	—	Clave API del proveedor.
model	<code>mistral-small-latest</code>	Modelo de generación.
temperature	0.1	Temperatura de muestreo (0.0–2.0).
max_tokens	1024	Tokens máximos en la respuesta generada.
context_chunks	15	Fragmentos incluidos en el prompt.

Reordenador.

Parámetro	Default	Descripción
reranker_enabled	true	Activa el cross-encoder de segunda etapa.
reranker_candidate_k	30	Candidatos pasados al reordenador.

Expansión hipotética (HyDE).

Parámetro	Default	Descripción
hyde_enabled	false	Activa la expansión hipotética de la consulta antes de la búsqueda vectorial, a costa

Detector de insuficiencia.

Parámetro	Default	Descripción
min_results	5	Mínimo de fragmentos para no activar búsqueda web.
expected_results	10	Resultados esperados (normaliza puntuación de cantidad).
min_top_score	0.35	Puntuación mínima del fragmento más relevante.
relevant_overlap_threshold	0.60	Fracción mínima de términos de la consulta que debe contener un fr
min_relevant_results	2	Mínimo de fragmentos relevantes requeridos.
min_coverage_score	0.20	Cobertura léxica mínima de la consulta.
min_answerability_score	0.40	Puntuación mínima de responsabilidad.
min_source_diversity	0.30	Diversidad mínima de URLs únicas entre resultados.
confidence_threshold	0.65	Umbral de confianza local; por debajo activa la búsqueda web.
coverage_top_n	5	Fragmentos del top usados para calcular cobertura.
w_top	0.10	Peso de la puntuación máxima normalizada.
w_quantity	0.15	Peso de la puntuación de cantidad.
w_coverage	0.35	Peso de la cobertura léxica.
w_diversity	0.15	Peso de la diversidad de fuentes.
w_answerability	0.25	Peso de la responsabilidad.

Los cinco pesos (`w_top`, `w_quantity`, `w_coverage`, `w_diversity`, `w_answerability`) deben sumar exactamente 1,0. La API valida esta restricción antes de aplicar cualquier cambio y rechaza la configuración si no se cumple.

6 Panel de ingesta y fuentes

Función del panel. Permite gestionar las fuentes de documentación del corpus: listar las fuentes configuradas, ejecutar ingestas sobre URLs registradas y subir archivos directamente al sistema. Es la sección desde la que el operador expande o actualiza el conocimiento disponible para el pipeline RAG sin necesidad de acceder al servidor.

Datos presentados. El endpoint `GET /api/v1/sources` devuelve la lista de fuentes configuradas con su identificador, URL raíz, estado y número de documentos indexados. El endpoint `POST /api/v1/ingest` ejecuta la ingesta y devuelve el número de fragmentos procesados y su distribución por fuente. El endpoint `POST /api/v1/upload` acepta archivos en formato PDF, HTML, Markdown

y texto plano; tras la carga informa el número de fragmentos generados, los identificadores asignados y el estado de la operación.

Parámetros editables.

Parámetro	Descripción
<code>source_id</code>	Identificador de la fuente a ingestar.
<code>force</code>	Booleano que fuerza la re-ingesta aunque los documentos ya existan en el índice.

7 Panel de métricas

Función del panel. Muestra estadísticas operativas del sistema en tiempo real. Su utilidad es permitir al operador monitorizar el estado del índice y el comportamiento del sistema sin acceder a los logs del servidor. Es un panel de solo lectura; no expone parámetros editables.

Datos presentados. El endpoint `GET /api/v1/metrics` expone el número total de fragmentos en el índice BM25 y en el índice vectorial, el número de documentos fuente indexados, el número de fragmentos en el caché web, el tiempo de respuesta promedio de las últimas consultas y el conteo de consultas que activaron búsqueda web externa.

8 Panel de retroalimentación de consultas

Función del panel. Implementa el módulo de *query feedback*. Permite ejecutar búsquedas con expansión pseudo-relevante de la consulta, registrar retroalimentación explícita sobre la relevancia de los fragmentos recuperados, y realizar búsquedas que incorporan ese historial de retroalimentación para reordenar los resultados. Es el panel desde el que el operador puede mejorar la calidad de la recuperación de forma iterativa, sin modificar el índice ni el pipeline.

Expansión de consulta. El endpoint `POST /api/v1/query-feedback/expand` aplica retroalimentación de pseudo-relevancia: recupera los fragmentos más relevantes para la consulta, extrae los términos más informativos y los añade a la consulta original. Devuelve la consulta expandida, la lista de términos añadidos, el método de expansión utilizado y el número de fragmentos empleados para la expansión.

Búsqueda con expansión y con retroalimentación. El endpoint `POST /api/v1/query-feedback/search` devuelve los campos de expansión más una lista de resultados enriquecidos con el identificador, puntuación, URL, título, breadcrumb y texto de cada fragmento. El endpoint `POST /api/v1/query-feedback/search-history` incorpora adicionalmente el historial de retroalimentación explícita para ajustar las puntuaciones. Cada resultado incluye la puntuación ajustada (`adjusted_score`), el boost aplicado (`feedback_boost`), si se aplicó retroalimentación (`feedback_applied`), el valor de relevancia registrado (0–3), el tipo de coincidencia con el historial (`exact` o `semantic`) y la similitud semántica con la consulta original del registro.

Registro de retroalimentación. El endpoint `POST /api/v1/query-feedback/feedback` permite al usuario registrar su valoración explícita sobre un fragmento recuperado. La interfaz muestra un selector de relevancia junto a cada resultado de búsqueda. Las valoraciones posibles son: 0 (irrelevante), 1 (marginamente relevante), 2 (relevante) y 3 (muy relevante). El campo `notes` acepta un comentario libre opcional.

Parámetros editables.

Parámetro	Tipo	Descripción
<code>query</code>	texto	Consulta a ejecutar.
<code>top_k</code>	entero	Número de resultados (1–50).
<code>top_k_feedback</code>	entero	Fragmentos para la expansión (1–50).
<code>max_expansion_terms</code>	entero	Términos máximos de expansión (0–20).
<code>expansion_enabled</code>	booleano	Activa la expansión pseudo-relevante.
<code>feedback_enabled</code>	booleano	Activa el reordenamiento por retroalimentación.
<code>semantic_feedback_enabled</code>	booleano	Activa la búsqueda semántica en el historial.
<code>semantic_similarity_threshold</code>	float	Umbral de similitud para coincidencias semánticas (0.0–1.0).
<code>chunk_id</code>	texto	Fragmento sobre el que se registra la valoración.
<code>relevance</code>	entero	Valoración: 0 irrelevante, 1 marginal, 2 relevante, 3 muy relevante.
<code>notes</code>	texto	Comentario libre opcional sobre la valoración.
<code>session_id</code>	texto	Identificador de sesión opcional.
<code>source_ids</code>	lista	Filtro opcional por fuentes específicas.

Resumen de retroalimentación. El endpoint `GET /api/v1/query-feedback/feedback/summary` devuelve estadísticas agregadas del historial: número total de valoraciones registradas, número de consultas únicas con al menos una valoración, conteos de valoraciones positivas (≥ 2), negativas ($= 0$) y marginales ($= 1$), y la media aritmética de todas las valoraciones.

9 Panel de evaluación

Función del panel. Permite gestionar el conjunto de evaluación del sistema: definir consultas de prueba con sus juicios de relevancia (*qrels*), ejecutar experimentos de recuperación y calcular métricas de calidad estándar de recuperación de información. Es la sección desde la que el operador puede medir el efecto de los cambios de configuración sobre la calidad objetiva del sistema.

Gestión de consultas y juicios. El endpoint `GET /api/v1/evaluation/queries` devuelve la lista de consultas de evaluación registradas. El endpoint `POST /api/v1/evaluation/queries` permite añadir nuevas consultas con su identificador, texto, descripción y juicios de relevancia asociados. El endpoint `POST /api/v1/evaluation/queries/{query_id}/rankings` ejecuta el pipeline de recuperación para una consulta de evaluación y almacena el ranking resultante. El endpoint `PUT /api/v1/evaluation/queries/{query_id}/judgments/{chunk_id}` permite registrar o actualizar manualmente el juicio de relevancia de un fragmento específico.

Métricas calculadas. El endpoint `GET /api/v1/evaluation/summary` calcula y devuelve las métricas agregadas del conjunto de evaluación completo: Precision@k, Recall@k, F1@k, MRR (*Mean*

Reciprocal Rank), DCG@k y NDCG@k. El endpoint `GET /api/v1/evaluation/report` devuelve el reporte detallado en formato JSON con métricas por consulta individual y promedios globales.

Parámetros editables.

Parámetro	Descripción
<code>query_id</code>	Identificador de la consulta de evaluación a gestionar.
<code>chunk_id</code>	Fragmento sobre el que se registra el juicio de relevancia.
<code>relevance</code>	Juicio de relevancia binario o graduado asignado al fragmento.

10 Resumen de endpoints por panel

Panel	Método	Endpoint
Chat RAG	POST	<code>/api/v1/rag/query</code>
Historial	GET	<code>/api/v1/rag/history/{session_id}</code>
Búsqueda híbrida	POST	<code>/api/v1/search</code>
Búsqueda caché web	POST	<code>/api/v1/search/web-cache</code>
Configuración (leer)	GET	<code>/api/v1/config</code>
Configuración (guardar)	POST	<code>/api/v1/config</code>
Fuentes	GET	<code>/api/v1/sources</code>
Ingesta	POST	<code>/api/v1/ingest</code>
Subida de archivo	POST	<code>/api/v1/upload</code>
Métricas	GET	<code>/api/v1/metrics</code>
Expansión de consulta	POST	<code>/api/v1/query-feedback/expand</code>
Búsqueda con expansión	POST	<code>/api/v1/query-feedback/search</code>
Búsqueda con feedback	POST	<code>/api/v1/query-feedback/search-with-feedback</code>
Registrar valoración	POST	<code>/api/v1/query-feedback/feedback</code>
Resumen de valoraciones	GET	<code>/api/v1/query-feedback/feedback/summary</code>
Valoraciones por consulta	GET	<code>/api/v1/query-feedback/feedback</code>
Consultas de evaluación	GET	<code>/api/v1/evaluation/queries</code>
Nueva consulta	POST	<code>/api/v1/evaluation/queries</code>
Ejecutar ranking	POST	<code>/api/v1/evaluation/queries/{id}/rankings</code>
Juicio de relevancia	PUT	<code>/api/v1/evaluation/queries/{id}/judgments/{cid}</code>
Resumen de evaluación	GET	<code>/api/v1/evaluation/summary</code>
Reporte de evaluación	GET	<code>/api/v1/evaluation/report</code>

11 Justificación técnica de la solución

La decisión de construir la interfaz como cliente puro de la API, sin lógica de negocio propia, responde a un principio de mantenibilidad: el sistema tiene varios módulos con parámetros ajustables en tiempo de ejecución, y cualquier duplicación de esa lógica en la capa de presentación introduciría una fuente de inconsistencias. Al delegar toda la computación al backend, la interfaz puede evolucionar independientemente del pipeline y viceversa.

La organización en ocho paneles diferenciados refleja la separación de responsabilidades del sistema. El panel de chat cubre el caso de uso primario; los paneles de búsqueda directa y configuración

cubren el uso operativo y de diagnóstico; los paneles de ingesta y métricas cubren la administración del corpus; los paneles de retroalimentación y evaluación cubren el ciclo de mejora continua de la calidad. Esta separación permite que distintos roles de usuario (usuario final, operador, ingeniero de datos) interactúen únicamente con la sección que les corresponde sin estar expuestos a la complejidad del resto.

La configuración en tiempo de ejecución expuesta en el panel de configuración es técnicamente necesaria porque los parámetros del sistema RAG no tienen valores óptimos universales. El umbral de confianza del detector de insuficiencia, los pesos de fusión híbrida o la temperatura del modelo dependen del perfil real de consultas y del contenido del corpus. Sin la capacidad de ajustarlos en caliente, cada experimento requeriría un reinicio del servidor y una modificación de las variables de entorno, lo que hace imposible el ajuste interactivo en un entorno de producción.

El panel de evaluación existe porque la calidad del sistema RAG no puede medirse únicamente de forma cualitativa. Las métricas estándar de recuperación de información (NDCG, MRR, Precision@k) proporcionan una señal objetiva y repetible que permite comparar configuraciones distintas, detectar regresiones al cambiar modelos y justificar decisiones técnicas con evidencia medible en lugar de impresiones subjetivas.

12 Limitaciones del módulo

La interfaz no tiene mecanismos de autenticación ni control de acceso. Cualquier usuario con acceso al puerto del servidor puede modificar la configuración del pipeline, disparar ingestas o registrar valoraciones. Esto es aceptable en un entorno de desarrollo interno pero no en un despliegue con acceso no restringido.

El panel de historial solo puede recuperar sesiones por su identificador exacto. No existe funcionalidad de búsqueda o listado de sesiones activas: el usuario debe conocer el `session_id` que usó en las consultas previas para poder acceder al historial. Sesiones cuyo identificador se pierda son irrecuperables desde la interfaz, aunque los datos persistan en Redis hasta que expire el TTL.

El panel de métricas expone estadísticas de nivel de sistema pero no métricas de calidad de recuperación en tiempo real. Para conocer si el sistema está respondiendo bien a las consultas recientes, el operador debe usar el panel de evaluación, que requiere construir un conjunto de prueba y ejecutar los rankings manualmente.

Los cambios de configuración del detector de insuficiencia surten efecto inmediatamente sobre las consultas siguientes pero no hay forma de comparar desde la interfaz el efecto de dos configuraciones distintas sobre el mismo conjunto de consultas sin registrar manualmente los resultados. La experimentación controlada requiere construir un conjunto de evaluación en el panel de evaluación antes de realizar cambios.